



Atelier 6 :

« Algorithme Apriori & Arbres de décision »

Faculté des sciences - Centre d'Excellence IT (Filière : ADIA/IL/IISE - S1)


Module : Informatique Décisionnelle

Pr: **Y. AIT LAHCEN**



Objectifs :

- Utiliser WEKA pour construire un arbre de décision.



1.2 Informations présentés :

Partie *Current relation* :

- **Relation** : Nom du fichier CSV utilisé, dans ce cas **exo1.csv**.
- **Instances** : Nombre d'instances contenues dans le fichier, ici 9.
- **Attributes** : Nombre d'attributs traités, ici 3, à savoir : *âge*, *revenu* et *ARisque*.

Partie *Selected attribute* : Cette partie donne des statistiques sur l'attribut sélectionné dans la section **Attributes**. Elle fournit notamment :

- Le **nom de l'attribut**.
- Le **type de l'attribut** : numérique ou texte.
- Le **nombre d'occurrences distinctes**.
- Le **minimum** et le **maximum**, si l'attribut est de type numérique.
- Le **nombre d'occurrences** de chaque valeur, si l'attribut est de type texte.

Environnement d'exécution :

- logiciel **WEKA** de data mining.

1 établir l'arbre de décision

1.1 lancez weka

- Lancez le logiciel **WEKA**.
- Pour vous connecter au fichier précédemment créé, cliquez sur **Explorer** dans la première fenêtre apparue lors du lancement de WEKA.
- Ensuite, dans l'onglet **Preprocess**, cliquez sur **Open file...**
- Dans la fenêtre qui s'ouvre, sélectionnez le type de fichier **CSV**, puis naviguez jusqu'à votre fichier **.csv** et cliquez sur **Ouvrir**.

Vous devez arriver à ce qui suit

Cette partie comporte également un **graphe en rectangles** composés de deux couleurs :

- Le **bleu** correspondant à **O : Oui à risque**.
- Le **rouge** correspondant à **N : Non à risque**.

On peut lire sur ce graphe qu'il existe deux **tranches de revenus** :

- Les revenus **inférieurs à 339**.
- Les revenus **supérieurs à 339**.


Cette valeur est obtenue par le calcul suivant :

$$\frac{\min + \max}{2} = 339$$

1.3 Construction de l'arbre de décision

Classification avec WEKA :


- Cliquez sur l'onglet **Classify**.
- Choisissez l'option **Use training set** comme suit :



Zone *Test options* : Cette zone permet de choisir la façon dont l'évaluation des performances du modèle appris sera réalisée.

- **Use training set** : utilise l'ensemble d'apprentissage pour l'évaluation.


- **Supplied test set** : utilise un autre fichier de test pour l'évaluation.
 - **Cross-validation** : l'ensemble d'apprentissage est divisé en 10 parties (si *Folds* vaut 10). L'algorithme apprend 10 fois sur 9 parties et le modèle est évalué sur la dixième partie restante. Les 10 évaluations sont ensuite combinées.
 - **Percentage split** : un pourcentage de l'ensemble d'apprentissage est utilisé pour l'apprentissage, et le reste pour l'évaluation.
- c) Ensuite, cliquer sur le bouton **Choose** de Classifier pour choisir un algorithme parmi ceux proposés par WEKA. Dans notre cas on va utiliser l'algorithme **J48**.



- Cliquer sur **Start** pour effectuer l'analyse.

1.4 Afficher l'arbre de décision

Pour afficher l'arbre cliquer droit dans la partie Result list ;



Question : déduire les règles de production ?

2 Règle d'association avec Weka

Pour lancer une opération de promotion, à une date donnée, on a opté pour les règles d'associations pour trouver des règles intéressantes. Pour préparer cette opération le bilan d'achats de l'année dernière à la même date a été réutilisé :

Achat	P_1	P_2	P_3	P_4	P_5
T1	X			X	X
T2	X	X			X
T3					X
T4			X	X	X
T5	X	X	X	X	X
T6	X				X
T7	X			X	X
T8		X	X		

Pour analyser les données des achats, nous créons un fichier `achat.arff` contenant les transactions sous forme binaire :

- 1 = produit acheté
- 0 = produit non acheté

(a) Lancez Weka et ouvrez l'Explorer.

(b) Chargez le fichier `achat.arff`.

(c) Allez dans l'onglet **Associate** pour accéder aux algorithmes de règles d'association.

(d) Sélectionnez l'algorithme **Apriori**.

(e) Vérifiez que l'algorithme fonctionne en le lançant sans modifier les paramètres.

Questions :

(a) Vérifiez que tout fonctionne en lançant l'algorithme sans modifier les paramètres du programme.

(b) Quelles sont les informations retournées par l'algorithme ?

(c) Extraire les règles d'associations avec un support de 0.5 puis de 0.1.

(d) Que pouvez-vous conseiller comme promotion à l'épicier ?

Annexe : Paramètres de l'algorithme Apriori

En cliquant avec le bouton droit dans la fenêtre située à droite du bouton **Choose**, on a accès aux paramètres de l'algorithme. Le bouton **More** détaille chacune de ces options.

- **delta** : fait décroître le support minimal de ce facteur, jusqu'à ce que soit le nombre de règles demandées ait été trouvé, soit on ait atteint la valeur minimale du support.
- **lowerBoundMinSupport** : valeur minimale du support (min-sup en cours). Le support part d'une valeur initiale et décroît conformément à **delta**.
- **metricType** : la mesure qui permet de classer les règles (par exemple : confiance, lift, conviction, etc.).

Fin de l'atelier : Algorithme Apriori & Arbres de décision.